

Cahier de Charges – Prédiction des Charges Médicales

1. Contexte et Objectif du Projet

1.1 Contexte

Ce projet s'inscrit dans le cadre du module **Machine Learning / Régression** du Master ISI. Il porte sur l'analyse et la modélisation d'un jeu de données de charges médicales individuelles aux États-Unis. L'objectif est d'appliquer une démarche complète de Data Science : de l'exploration des données jusqu'à la modélisation et l'évaluation des performances.

1.2 Objectif Principal

Prédire le montant des charges médicales (`charges`) facturées à un individu en fonction de ses caractéristiques personnelles (âge, sexe, IMC, nombre d'enfants, statut fumeur, région géographique).

1.3 Jeu de Données

- **Fichier** : `medical-charges.csv`
 - **Nombre d'observations** : 1 339
 - **Nombre de variables** : 7 (6 features + 1 target)
-

2. Description du Dataset

Variable	Type	Description	Valeurs possibles
<code>age</code>	Numérique	Âge du bénéficiaire principal	18 - 64 ans
<code>sex</code>	Catégorielle	Sexe du bénéficiaire	<code>female</code> , <code>male</code>
<code>bmi</code>	Numérique	Indice de Masse Corporelle (Body Mass Index)	Valeur continue (ex. 15.96 - 53.13)
<code>children</code>	Numérique	Nombre d'enfants / dépendants couverts par l'assurance	0 - 5
<code>smoker</code>	Catégorielle	Le bénéficiaire est-il fumeur ?	<code>yes</code> , <code>no</code>
<code>region</code>	Catégorielle	Zone résidentielle du bénéficiaire aux États-Unis	<code>southwest</code> , <code>southeast</code> , <code>northwest</code> , <code>northeast</code>
<code>charges</code>	Numérique	Charges médicales individuelles facturées par l'assurance (variable cible)	Valeur continue (ex. 1 121 - 63 770)

3. Travail Demandé

Le projet se décompose en **7 phases** détaillées ci-dessous :

Phase 1 – Analyse Exploratoire des Données (EDA)

L'exploration doit fournir une compréhension approfondie du dataset avant toute transformation.

Tâches :

1. Chargement et inspection initiale :

- `df.head()`, `df.tail()`, `df.shape`, `df.info()`, `df.describe()`
- Vérification des types de données

2. Analyse univariée :

- Distribution de chaque variable numérique (`age`, `bmi`, `children`, `charges`) via histogrammes et boxplots
- Comptage des modalités pour les variables catégorielles (`sex`, `smoker`, `region`) via countplots

3. Analyse bivariable :

- Relation entre chaque feature et la variable `charges` (scatter plots, boxplots par catégorie)
- Analyse de l'impact du statut `smoker` sur les `charges`
- Analyse de l'interaction `bmi × smoker` sur les `charges`

4. Analyse multivariée :

- Matrice de corrélation (heatmap) entre les variables numériques
- Pairplot coloré par `smoker`

5. Détection des outliers :

- Méthode IQR (Interquartile Range) sur les variables numériques
- Visualisation via boxplots

Livrables :

- Visualisations commentées (matplotlib / seaborn)
 - Observations et conclusions textuelles dans des cellules Markdown
-

Phase 2 – Nettoyage et Prétraitement (Cleaning & Preprocessing)

Tâches :

1. Gestion des valeurs manquantes :

- Vérification avec `df.isnull().sum()`
- Stratégie de traitement si nécessaire (imputation ou suppression)

2. Gestion des doublons :

- Détection avec `df.duplicated().sum()`

- Suppression si doublons exacts

3. Encodage des variables catégorielles :

- **Label Encoding** ou **One-Hot Encoding** pour `sex`, `smoker`, `region`
- Justification du choix d'encodage

4. Feature Scaling :

- Standardisation (`StandardScaler`) ou Normalisation (`MinMaxScaler`)
- Application sur les variables numériques

5. Séparation des données :

- Définition de `X` (features) et `y` (target = `charges`)
- Split `train / test` (80% / 20%) avec `train_test_split` et `random_state` fixé

Livrables :

- Dataset nettoyé et transformé prêt pour la modélisation
- Justification de chaque choix de prétraitement

Phase 3 – Modélisation (Linear Regression + Régularisation)

Modèles à implémenter :

#	Modèle	Description
1	Linear Regression	Régression linéaire simple (OLS - Ordinary Least Squares)
2	Ridge Regression	Régularisation L2 – pénalise les grands coefficients ($\alpha \neq 0$)
3	Lasso Regression	Régularisation L1 – peut mettre certains coefficients à 0
4	ElasticNet	Combinaison de L1 + L2 (paramètres α et <code>l1_ratio</code>)

Tâches :

1. Entraîner chaque modèle sur le jeu d'entraînement
2. Effectuer des prédictions sur le jeu de test
3. Afficher et interpréter les **coefficients** de chaque modèle
4. Utiliser `cross_validation` pour évaluer la robustesse
5. Optionnel : recherche des meilleurs hyperparamètres via `GridSearchCV` ou `RidgeCV` / `LassoCV`

Livrables :

- Modèles entraînés et prédictions
 - Tableau comparatif des coefficients
-

Phase 4 – Évaluation des Modèles

Métriques d'évaluation :

Métrique	Formule / Description
RMSE	$\sqrt{\frac{1}{n} \sum (y_i - \hat{y}_i)^2}$ – Erreur quadratique moyenne
MAE	$\frac{1}{n} \sum$
R ²	Coefficient de détermination – proportion de variance expliquée
Adjusted R ²	R ² ajusté tenant compte du nombre de features
MAPE (optionnel)	Erreur absolue moyenne en pourcentage

Tâches :

1. Calculer les métriques ci-dessus pour **chaque modèle**
2. Créer un **tableau récapitulatif** comparant les performances
3. Visualiser les **résidus** (distribution, scatter plot résidus vs prédictions)
4. Tracer les **valeurs réelles vs prédites** (scatter plot)
5. Interpréter les résultats et identifier le meilleur modèle

Livrables :

- Tableau comparatif des métriques (DataFrame)
- Graphiques d'analyse des résidus
- Interprétation textuelle

Phase 5 – Sélection de Features (Feature Selection)

Méthodes à appliquer :

1. **Backward Elimination** :
 - Partir de toutes les features
 - Supprimer itérativement la feature avec la plus grande p-value (seuil > 0.05)
 - Utiliser `statsmodels` OLS pour obtenir les p-values
 - Documenter chaque itération
2. **RFE (Recursive Feature Elimination)** (optionnel) :
 - Utiliser `RFE` de scikit-learn avec `LinearRegression` comme estimateur
 - Sélectionner le nombre optimal de features
3. **Analyse des coefficients Lasso** :
 - Identifier les features mises à zéro par Lasso (coefficient = 0)

Tâches :

1. Appliquer la Backward Elimination pas à pas
2. Lister les features éliminées et celles retenues
3. Justifier la sélection finale

Livrables :

- Tableau des p-values à chaque itération
 - Liste des features sélectionnées
 - Explication de l'algorithme en Markdown
-

Phase 6 – Comparaison : Tous les Features vs Features Sélectionnées

Tâches :

1. **Ré-entraîner** tous les modèles (Linear Regression, Ridge, Lasso, ElasticNet) avec les **features sélectionnées** uniquement
2. **Recalculer** toutes les métriques d'évaluation (RMSE, MAE, R^2 , Adj. R^2)
3. **Construire un tableau comparatif** :
 - Lignes : modèles
 - Colonnes : métriques avec **All Features** vs **Selected Features**
4. **Visualiser** la comparaison (bar chart groupé)
5. **Analyser** l'impact de la sélection de features :
 - Y a-t-il une amélioration ou dégradation ?
 - Le modèle est-il plus simple sans perte significative de performance ?

Livrables :

- Tableau comparatif complet
 - Graphiques de comparaison
 - Analyse et discussion
-

Phase 7 – Conclusion

Contenu attendu :

1. **Résumé des résultats** :
 - Meilleur modèle identifié
 - Features les plus importantes pour la prédiction
2. **Observations clés** :
 - Impact du statut fumeur sur les charges

- Rôle de l'âge et de l'IMC

3. Limites du projet :

- Taille du dataset
- Hypothèses de linéarité
- Variables manquantes potentielles

4. Perspectives d'amélioration :

- Modèles non-linéaires (Decision Tree, Random Forest, XGBoost)
- Feature Engineering (interactions, transformations polynomiales)
- Collecte de données supplémentaires

4. Outils et Technologies

Catégorie	Outils
Langage	Python 3.x
Environnement	Jupyter Notebook
Librairies	pandas, numpy, matplotlib, seaborn, scikit-learn, statsmodels
IDE	VS Code / Jupyter Lab

5. Structure du Notebook

Le notebook final doit suivre la structure suivante :

1. Introduction et Description du Dataset
2. Importation des Librairies
3. Chargement des Données
4. Analyse Exploratoire (EDA)
 - 4.1 Analyse Univariée
 - 4.2 Analyse Bivariée
 - 4.3 Analyse Multivariée
 - 4.4 Détection des Outliers
5. Nettoyage et Prétraitement
 - 5.1 Valeurs Manquantes
 - 5.2 Doublons
 - 5.3 Encodage
 - 5.4 Feature Scaling
 - 5.5 Train/Test Split
6. Modélisation
 - 6.1 Linear Regression

- 6.2 Ridge Regression
- 6.3 Lasso Regression
- 6.4 ElasticNet Regression
- 7. Évaluation des Modèles
 - 7.1 Métriques
 - 7.2 Analyse des Résidus
 - 7.3 Tableau Comparatif
- 8. Sélection de Features
 - 8.1 Backward Elimination
 - 8.2 RFE (optionnel)
 - 8.3 Analyse Lasso
- 9. Comparaison All Features vs Selected Features
- 10. Conclusion

6. Critères de Réussite

- ☐ Dataset correctement chargé et exploré
- ☐ EDA complète avec visualisations pertinentes
- ☐ Prétraitement justifié et documenté
- ☐ Au moins 4 modèles de régression entraînés
- ☐ Métriques d'évaluation calculées et comparées
- ☐ Feature Selection appliquée et documentée
- ☐ Comparaison All Features vs Selected Features réalisée
- ☐ Conclusion synthétique et perspectives

Note : Chaque phase doit être documentée avec des cellules Markdown explicatives dans le notebook. Le code doit être commenté et reproductible.